

MCA Detector 專案說明書

版本：2026-05-17

分支：feature/llm-data-pipeline

用途：專題交接、論文撰寫、demo 展示前說明

1. 專案定位

MCA Detector 是一套針對社群平台中「可疑協同行為」的分析流程。它的目標不是直接宣稱某個帳號是機器人、網軍或真實世界中的操控者，而是產生可重跑、可解釋、可人工審查的高風險候選群。

核心問題是：

單一帳號看起來可疑，不代表它屬於協同群；多個帳號攻擊同一批目標，也不一定代表它們由同一操控者控制。

因此專案採用兩階段邏輯：

1. 先找候選協同群：用 MCA 分數找 seed accounts，再用 adjacency graph 做 seed expansion。
2. 再做時間驗證：用 temporal synchrony 判斷群內帳號是否在同一討論串短時間共同出現。

2. 專案與 Demo 網站的界線

本專案分成「分析 pipeline」與「展示層」兩部分。

分析 pipeline 是研究方法本體：

raw data -> LLM analysis -> features / graphs -> MCA scoring
-> seed expansion -> temporal verification -> output tables

MCA-demo-site/ 是展示層：

coordination-expansion/output -> MCA-demo-site/data/demo-data.js -> dashboard

Demo 網站不計算 MCA 分數、不發現群組、不做 temporal verification，也不是 final verdict。它只是把 pipeline 已產生的 evidence tables 包裝成 client-facing 或 demo-facing 介面。

3. 主要資料流

整體 pipeline：

raw posts/comments
-> LLM post/comment analysis
-> account feature matrix
-> adjacency graphs
-> MCA seed ranking
-> coordination expansion
-> Stage 2 temporal verification
-> candidate validation table
-> final group summary
-> account role table

目前 runner 分成三個入口：

Runner	用途
run_front_pipeline.py	從 raw posts/comments 跑到 analyzed exports、feature matrix、adjacency graphs
run_back_pipeline.py	從既有 graph/features 跑 MCA、expansion、verification、summary
run_full_pipeline.py	前半與後半一次跑完

常用指令：

```
.venv/bin/python run_front_pipeline.py \  
--raw-posts llm/data-cleaning/source_data/reddit_posts_2025.csv \  
--raw-comments llm/data-cleaning/source_data/reddit_comments_2025.csv \  
--llm-provider ollama \  
--llm-workers 2
```

```
.venv/bin/python run_back_pipeline.py --top-n-seeds 20
```

```
.venv/bin/python run_full_pipeline.py \  
--raw-posts llm/data-cleaning/source_data/reddit_posts_2025.csv \  
--raw-comments llm/data-cleaning/source_data/reddit_comments_2025.csv \  
--llm-provider ollama \  
--llm-workers 2 \  
--top-n-seeds 20
```

LLM backend：

Provider	說明
ollama	目前建議使用的本地 LLM backend
gemini	Vertex/Gemini 舊流程或雲端備用
none	不重跑 LLM，直接使用既有 llm/Export

4. 模組說明

4.1 llm/

負責對 Reddit 貼文與留言做 LLM 分析。

貼文分析輸出：

- sentiment_score
- manipulative_rhetoric_score
- manipulative_rhetoric_reason
- rhetoric_tags

留言分析輸出：

- feedback_label
- feedback_score
- edge_weight

留言會被轉成 account-to-account edge：

```
comment_author -> post_author
```

若留言反對或攻擊原貼文，則形成負向互動；若支持或補充，則形成正向互動。

4.2 behavior/

負責建立帳號行為特徵與 anomaly label。主要特徵包括：

- comment_count
- post_count
- comments_per_day
- posts_per_day

- active_days
- burst_ratio
- night_activity_ratio
- weekend_activity_ratio
- comment_post_ratio

注意：behavior anomaly 不是 bot verdict。它只能說某個帳號的活動模式異常，不能單獨證明該帳號屬於協同群。

4.3 adjacency/

負責建立多層 account-level graph。主要輸出包括：

Graph	意義	正式用途
A_count	純留言次數	baseline / EDA
A_signed	支持/反對方向與強度	interaction graph
A_positive	正向互動	visualization / EDA
A_negative	負向互動	visualization / EDA
A_trigger_response	A 發文後 B 是否固定回應	expansion support
A_co_target	兩帳號是否留言到同一批目標	support signal
A_co_negative_target	兩帳號是否共同攻擊同一批目標	candidate discovery 主訊號
A_tag_similarity	rhetoric tag profile 是否相似	EDA / visualization，不進正式分數

最重要的是 A_co_negative_target。它回答：

兩個帳號是否常常反對或攻擊同一批作者？

但這不是 final verdict，因為正常使用者也可能因立場相同而共同批評同一批人。

4.4 mca-scoring/

負責建立 account-level MCA review priority score。MCA 不是最終判決，而是 seed selection 與 review priority。

四個 signal：

Signal	權重	主要特徵
Manipulative	0.30	平均修辭分數、非中立貼文比例、反對立場比例
Coordinative	0.35	co-target、co-negative-target、trigger-response frequency
Interaction reach	0.15	outgoing volume、incoming attention、interaction breadth
Automatic behavior	0.20	Isolation Forest anomaly score

這些權重是常理型初始權重，不是 supervised optimal weights。因為目前沒有大規模 ground truth，不適合宣稱已找到最佳權重。

4.5 coordination-expansion/

負責把 MCA seed 與 graph artifacts 轉成可審查的候選群。

流程：

MCA top accounts
-> seed expansion / group discovery
-> Stage 2 temporal verification

-> candidate validation table
-> final group summary
-> account roles

Seed selection 預設取 MCA primary ranking top 20。

Tiered expansion :

Tier	納入條件	意義
Tier 1	co_negative_target >= 0.20	共同負向目標高度重疊
Tier 2	tag_similarity >= 0.90 且有結構訊號	語言/修辭近似，但需支持
Tier 3	trigger_response >= 0.50 且有 co-negative 或 tag support	固定回應模式
Tier 4	2-hop co-negative，且連到至少 2 個已納入成員	外圍候選成員

co_target 是輔助訊號，不單獨納入。

5. Stage 2 Temporal Verification

Stage 1 找到的是 candidate coordination groups，不是同操控者證據。Stage 2 檢查群內帳號是否在同一篇 post 下短時間共同出現。

Pair-level labels :

Label	定義
strong_temporal_sync	至少一次同串留言時間差小於 5 分鐘
moderate_temporal_sync	至少兩次同串留言時間差小於 30 分鐘
weak_temporal_overlap	有同串共現，但沒有短時間同步
no_temporal_sync	沒有同串共現

Temporal confidence :

Confidence	意義
robust	重複或跨多篇貼文的短時間同步
moderate_review	有可審查同步證據，但仍需人工確認
fragile	單次或典型延遲太長，只作 context
none	沒有可用同步證據

正式 Stage 2 只使用：

- temporal synchrony
- temporal confidence

已移除的 formal evidence :

- text_fingerprint_distance
- account_lifecycle_overlap

移除原因：

1. Text fingerprint 在單一主題社群中容易測到 topic similarity，而不是 same operator。

2. Lifecycle / activation overlap 在 harvested 與 JG87919 類型案例中無法分開正反樣本。

3. 操控者可以刻意改變文字風格與帳號生命週期，因此這些訊號不穩定。

欄位仍可保留在 CSV schema 中作相容用途，但正式 ranking、validation、demo 解讀不使用它們。

6. 目前主要輸出

重要輸出檔：

檔案	說明
coordination-expansion/output/selected_seeds.csv	被選為 expansion 起點的 seed accounts
coordination-expansion/output/seeds/<seed>/tiered_expansion_members.csv	每個 seed 的擴張成員與納入理由
coordination-expansion/output/stage2-verification/stage2_verification_evidence.csv	pair-level temporal evidence
coordination-expansion/output/candidate-validation/candidate_validation_table.csv	account-level review priority table
coordination-expansion/output/final-summary/final_group_summary.csv	group-level review priority summary
coordination-expansion/output/account-roles/account_role_table.csv	group member role labels

目前 pipeline output 摘要：

指標	數值
Selected seed accounts	20
Candidate seed groups	20
Group membership rows	178
Unique candidate accounts	172
Strong temporal sync pairs	13
Moderate temporal sync pairs	8
Robust temporal pairs	3
Moderate-review temporal pairs	44

注意：這些數字是 review output，不是 accuracy。

7. 案例解讀

7.1 harvested 群組

harvested 是目前最清楚的高優先案例之一。它在 Stage 1 中具有：

- 8 名 group members
- 7 名 Tier 1 co-negative direct members
- 9 條 internal coordination edges

- 11 個 shared negative targets

Stage 2 中，NectarineDirect936 與 harvested 在 17 篇共同貼文中出現，包含：

- 2 次 5 分鐘內同步
- 4 次 30 分鐘內同步
- temporal label: strong_temporal_sync
- temporal confidence: robust

解讀：共同攻擊目標與穩定時間同步同時存在，因此是高優先審查群。

7.2 JG87919 類型案例

JG87919 類型案例用來提醒 Stage 1 不能直接當作最終判斷。它在 Stage 1 中形成：

- 15 名候選成員
- 34 條 internal coordination edges
- 20 個 shared negative targets

但後續檢查顯示，它更像同一社群中立場相近的獨立使用者，而不是同操控來源。這說明 co-negative-target 可以找到「共同攻擊同一批人」的群，但不能直接證明「同一操控者」。

8. Account Roles

為了讓群組結果更容易人工閱讀，系統產生簡單角色標註：

Role	中文說明	規則
leader_instigator	帶頭起鬧	seed 本人
comment_attacker	留言攻擊者	oppositional comment ratio ≥ 0.50
comment_supporter	留言支持者	supportive comment ratio ≥ 0.50
context_member	背景成員	其他被 expansion 保留者

角色定位不是人格判斷，也不是 final verdict，只是幫助審查者理解群內行為分工。

9. Demo Site

MCA-demo-site/ 是多頁靜態展示網站，包含：

Page	用途
index.html	Executive overview 與 review priorities
groups.html	Risk group queue、關係圖、pair evidence
accounts.html	Individual abnormal account stream
methodology.html	Pipeline 與 signal pruning 說明

網站支援：

- 中文 / English 切換
- Client mode / Demo mode 切換
- MCA Sentinel 品牌與企業風險面板視覺

網站主要給老師、client 或非技術觀眾快速理解結果；研究方法仍以 pipeline 與 output tables 為準。

10. 重要設計決策

決策	原因
MCA score 不作 final verdict	單一帳號分數不能證明協同或操控
co-negative-target 用於 discovery，不作 verdict	正常同立場使用者也可能共同攻擊同一批人
Stage 2 收斂為 pure temporal verification	text fingerprint 與 lifecycle 在本資料集中像噪音
Demo site 與 project pipeline 分開	網站是展示層，不是分析方法本體
使用 Ollama 作主要 LLM backend	之後較適合本地重跑與跨平台擴充
Runner 拆成前半、後半、整份	目前 pipeline 尚在調整，拆開有利 debug 與重跑

11. 專題與論文主張

本專題不應說：

我們用 MCA 分數找到了網軍。

建議說：

我們提出一套可審查的協同行為偵測流程。先用 MCA 分數找可疑 seed，再用共同負向目標圖擴張為候選群，最後用短時間同步驗證，區分同立場活躍使用者與更可疑的協同行動。

這樣比較準確，也比較不會過度宣稱。

12. 目前限制

1. 缺乏大規模 ground truth，因此不能宣稱 supervised accuracy。
2. Temporal synchrony 仍可能受到熱門貼文與高活躍使用者影響。
3. Text fingerprint 與 lifecycle 已被測試但不適合作 formal evidence。
4. Reddit 原始資料缺少部分跨平台需要的欄位，例如完整 subreddit distribution。
5. 不同平台的 action traces 不同，未來若做插件或跨平台工具，需要重新定義平台行為。

13. 下一步建議

短期：

1. 將本文說明書內容整理進 4-6 頁投稿論文。
2. 將 final group summary 做成更清楚的結果表。
3. 為 harvested 與 JG87919 類型案例補上圖示與審查說明。
4. Demo site 保持展示層，不再塞入分析邏輯。

中期：

1. 建立人工標註的小型正反樣本集。
2. 測試 temporal threshold 在其他資料集上的穩定性。
3. 擴充不同平台的 action trace，例如 repost、share link、hashtag、like、reply chain。
4. 將 pipeline 包裝成可定期重跑的 monitoring workflow。

14. 快速交接摘要

一句話版本：

MCA Detector 不是直接抓網軍，而是從可疑帳號出發，找出可能一起行動的群，再用時間同步證據排序審查優先級。

三層邏輯：

1. Account suspiciousness: MCA score
2. Group candidate discovery: co-negative-target expansion
3. Verification: temporal synchrony

最重要的輸出：

- final_group_summary.csv
- stage2_verification_evidence.csv
- candidate_validation_table.csv
- account_role_table.csv

最重要的觀念：

協同不等於網軍；共同攻擊目標不等於同操控者；因此我們用 temporal verification 來降低誤判。